

Aprendizado de Máquina - Machine Learning

Prof. MSc. Sergio Luiz Marques Filho

Assuntos abordados:

Aprendizado Supervisionado
Aprendizado Não-Supervisionado
Classificação e Regressão
Google Colab
K-Nearest Neighbors - KNN
Regressão Linear
Regressão Logística
Métricas e Erros de Classificação e Regressão
Árvores de Decisão
Support Vector Machines – SVM
Processamento da Linguagem Natural – PLN
Agrupamento com K-Means
Séries Temporais

Bases de dados

Espécies de flores Iris
Diabetes
Câncer de Mama
Preços de Residências
Consumo de Combustível
Admissão em Universidades
Dígitos Manuscritos
Rostos de figuras públicas
Análise de Sentimentos em Tweets
Diálogos de Personagens da série South Park
Passagens Aéreas

Sumário

Introdução Aprendizado de Máquina	5
Tipos de aprendizado de máquina	5
Tipos de aprendizado supervisionado	5
Introdução ao aprendizado supervisionado	6
Regressão para obtenção de valores numéricos	6
Classificação para obtenção de respostas categóricas	6
Vocabulário de aprendizado de máquina	7
Exemplo Classificação Iris	7
Introdução ao Google Colab	9
Aceleração de hardware	9
Upload de arquivo montando um drive no Google Drive	9
Tarefas Básicas no Colab	10
Importar um notebook existente	10
Pandas	11
Importando arquivos para Dataframe	11
Exemplo gráfico com importação de biblioteca	13
Exemplo importação de biblioteca scipy	14
K-Nearest Neighbors (KNN)	16
Medindo as distâncias com KNN	16
Características do modelo KNN	17
Divisão conjunto de treinamento e conjunto de testes	17
Validação cruzada	18
Aplicação K Nearest Neighbors na base de dados Iris	20
Iris Dataset	20
Aplicação K Nearest Neighbors na base de dados diabetes	21
Pima Indians Diabetes Dataset	21
Regressão Linear	22
Erro	22
Erro quadrático médio	23
Aplicação Regressão Linear na base de dados Boston House Prices	24
Boston House Prices Dataset	24
Aplicação Regressão Linear na base de dados Consumo de Combustível	25
Petrol Consumption Dataset	25
Regressão Linear para Classificação (Regressão Logística)	26
Classificação com Regressão Logística	27

Aplicação Regressão Logística na base de dados Marks - exame de admissão na universidade	29
Marks Dataset	29
Aplicação Regressão Logística na base de dados Mnist.....	30
Mnist Dataset	30
Métricas de Erro de Classificação.....	31
Matriz de confusão.....	31
Métricas comuns de aprendizado de máquina.....	31
Receiver Operating Characteristic (ROC) e Area Under Curve (AUC)	32
Support Vector Machine	34
Classificação com SVMs	34
SVM – Lineares	34
Aplicação Support Vector Machine na base de dados de reconhecimento de faces de figuras públicas	35
Labeled Faces in the Wild Dataset	35
Aplicação Support Vector Machine na base de dados Breast Cancer	36
Breast Cancer Wisconsin (Diagnostic) Dataset	36
Processamento da Linguagem Natural	37
Técnicas de pré-processamento	37
Similaridade de Documentos	38
Aplicação Processamento da Linguagem Natural na base de dados de Análise de Sentimentos de texto Twitter.....	40
Sentiment Analysis Tweets Dataset	40
Aplicação Processamento da Linguagem Natural na base de dados de detecção personagens do South Park	41
Detecção Personagens South Park Dataset	41
Introdução ao aprendizado não-supervisionado	42
Exemplo Usuários de Seguro Saúde.....	42
Tipos de aprendizado não-supervisionado	42
Algoritmo K-Means	43
Encontrar o melhor valor para K.....	43
Aplicação agrupamento na base de dados Mnist	44
Mnist Dataset	44
Séries Temporais	45
Aplicação Série Temporal na base de dados Passagens Aéreas	46
Air Passenger Dataset	46
Template de Relatório de Ciência de Dados	47
Obtendo Dados	48

Gerando dados para regressão linear	48
Gerando dados para classificação	48
Referências.....	51

Aprendizado de Máquina - Machine Learning

Introdução Aprendizado de Máquina

Aprendizado de máquina permite ao computador aprender e inferir a partir dos dados.

Tipos de aprendizado de máquina

Supervisionado

- O conjunto de dados tem saída conhecida

Não-Supervisionado

- A saída do conjunto de dados não é conhecida

Tipos de aprendizado supervisionado

Regressão


- Saída é **contínua** (numérica)

Classificação


- Saída é uma **categoria**.

Introdução ao aprendizado supervisionado


“Modelo é a especificação de uma relação matemática ou probabilística existente entre variáveis diferentes” (GRUS, 2016).



Regressão para obtenção de valores numéricos



Classificação para obtenção de respostas categóricas



Vocabulário de aprendizado de máquina

Target	•Categoria predita ou valor do dado
Característica	•Propriedades do dado usadas para predição.
Exemplo	•Um ponto dentro do conjunto de dados
Label	•Rótulo, valor alvo para um ponto dos dados.

Exemplo Classificação Iris

Categorias/Label/Target



Iris Versicolor



Iris Setosa



Iris Virginica

Características/Features




Figura 1 Fonte: <https://bishwamittra.github.io/imli.html>, acessado em 01/2020.

Características					Alvo/Target
comprimento sépala	largura sépala	comprimento pétala	largura pétala		Espécie
69	5.5	2.5	4.0	1.3	Iris-versicolor
89	7.2	3.6	6.1	2.5	Iris-virginica
86	4.9	2.5	4.5	1.7	Iris-virginica
109	7.2	3.0	5.8	1.6	Iris-virginica
10	4.8	3.1	1.6	0.2	Iris-setosa
85	7.6	3.0	6.6	2.1	Iris-virginica
29	5.0	3.3	1.4	0.2	Iris-setosa
6	5.0	3.4	1.6	0.4	Iris-setosa
77	6.2	2.9	4.3	1.3	Iris-versicolor
56	6.8	2.8	4.8	1.4	Iris-versicolor
84	6.5	3.0	5.8	2.2	Iris-virginica
36	6.3	3.3	4.7	1.6	Iris-versicolor
74	5.6	2.7	4.2	1.3	Iris-versicolor
97	7.7	3.8	6.7	2.2	Iris-virginica
93	5.7	2.5	5.0	2.0	Iris-virginica

Rótulos



Introdução ao Google Colab

Colab é a plataforma do Google para codificação online compartilhada, disponível no endereço <https://colab.research.google.com/>.

- Jupyter notebook environment
- Integrado com o Google Drive

Aceleração de hardware

Clique em “Runtime” e escolha “Change runtime type”



Upload de arquivo montando um drive no Google Drive

É necessário providenciar um ticket de autorização.

```
from google.colab import drive
drive.mount('/mntDrive')


... Go to this URL in a browser: https://accounts.google.com/o/oauth2/auth?client\_id=947318989803-6bn6pk8gdf4n4g3pfee6491hc0brcd1.apps.googleusercontent.com&redirect\_uri=https://colab.research.google.com/&scope=https://www.googleapis.com/auth/drive

Enter your authorization code:


```

Tarefas Básicas no Colab


1. Criar um novo programa python



2. Criar um programa Hello World!



Importar um notebook existente



Pandas

Biblioteca para computação de dados em formato tabulas, que permite múltiplos tipos de dados nas colunas de uma única tabela.

Provê facilidades para nomear colunas e fornecer dados sumarizados e agregados por funções estatísticas.

PYTHON	PANDAS
VETOR DE 1 DIMENSÃO	Series
ARRAY DE 2 DIMENSÕES	Dataframe

Importando arquivos para Dataframe

```
import pandas as pd
from google.colab import drive
drive.mount('/content/gdrive')
boxoffice_df = pd.read_csv("/content/gdrive/My Drive/Colab Notebook
s/boxoffice.csv")
boxoffice_df.head()
```

	rank	title	studio	lifetime_gross	year
0	1	Star Wars: The Force Awakens	BV	936662225	2015
1	2	Avengers: Endgame	BV	857190335	2019
2	3	Avatar	Fox	760507625	2009
3	4	Black Panther	BV	700059566	2018
4	5	Avengers: Infinity War	BV	678815482	2018

Renomeando as colunas


```
import pandas as pd
from google.colab import drive
names = ['Id', 'Título', 'Estúdio', 'Receita', 'Ano',]
drive.mount('/content/gdrive')
boxoffice_df = pd.read_csv("/content/gdrive/My Drive/Colab Notebooks/boxoffice.csv", skiprows=1, header=None, names=names)
boxoffice_df.head(15)
```

	Id	Título	Estúdio	Receita	Ano
0	1	Star Wars: The Force Awakens	BV	936662225	2015
1	2	Avengers: Endgame	BV	857190335	2019
2	3	Avatar	Fox	760507625	2009
3	4	Black Panther	BV	700059566	2018
4	5	Avengers: Infinity War	BV	678815482	2018
5	6	Titanic	Par.	659363944	1997
6	7	Jurassic World	Uni.	652270625	2015
7	8	Marvel's The Avengers	BV	623357910	2012
8	9	Star Wars: The Last Jedi	BV	620181382	2017
9	10	Incredibles 2	BV	608581744	2018
10	11	The Dark Knight	WB	535234033	2008
11	12	Rogue One: A Star Wars Story	BV	532177324	2016
12	13	Beauty and the Beast (2017)	BV	504014165	2017
13	14	Finding Dory	BV	486295561	2016
14	15	Star Wars: Episode I - The Phantom Menace	Fox	474544677	1999

Exemplo gráfico com importação de biblioteca


Exemplo de gráfico

```
▶ import matplotlib.pyplot as plt  
import numpy as np  
  
X = np.linspace(-np.pi, np.pi, 256, endpoint=True)  
C, S = np.cos(X), np.sin(X)  
  
plt.plot(X, C)  
plt.plot(X, S)  
plt.show()
```



Exemplo gráfico 3D

```
from mpl_toolkits.mplot3d import Axes3D
fig = plt.figure()
ax = Axes3D(fig)
X = np.arange(-4, 4, 0.25)
Y = np.arange(-4, 4, 0.25)
X, Y = np.meshgrid(X, Y)
R = np.sqrt(X**2 + Y**2)
Z = np.sin(R)
ax.plot_surface(X, Y, Z, rstride=1, cstride=1, cmap='hot')
plt.show()
```



Exemplo importação de biblioteca scipy

Import das bibliotecas

```
▶ import numpy as np
   from scipy import linalg

   arr = np.array([[1, 2],
                   [3, 4]])

   print("Matriz")
   print(arr)

   print("Determinante da matriz")
   print(linalg.det(arr))
```

```
↳ Matriz
   [[1 2]
    [3 4]]
   Determinante da matriz
   -2.0
```