

K-Nearest Neighbors (KNN)

O que é necessário para a classificação?


Modelar os dados

- **Características** que possam ser **quantificadas**
- **Rótulos** que são conhecidos.

Método para medir a **similaridade**

Para desenvolver um modelo KNN é necessário:

- Valor correto de K
- Métrica para medir a proximidade dos vizinhos.



Medindo as distâncias com KNN

- Distância Euclidiana
- Manhattan Distance



$$Distância\ Euclidiana = \sqrt{\Delta NumeroNósMalignos^2 + \Delta Idade^2}$$

Características do modelo KNN

- Fácil de criar porque simplesmente armazena os dados.
- Lento para calcular devido ao elevado número de distâncias que são necessárias calcular
- Pode requerer grande quantidade de memória se o conjunto de dados for grande.

Divisão conjunto de treinamento e conjunto de testes

Conj. de Treinamento

- Ajuste do modelo

Conj. de Testes


- Medir desempenho
- Prever rótulo com o modelo → Comparar com o valor real → Mensurar erros.

	Id	Título	Estúdio	Receita	Ano	
	0	1	Star Wars: The Force Awakens	BV	936662225	2015
	1	2	Avengers: Endgame	BV	857190335	2019
	2	3	Avatar	Fox	760507625	2009
	3	4	Black Panther	BV	700059566	2018
	4	5	Avengers: Infinity War	BV	678815482	2018
	5	6	Titanic	Par.	659363944	1997
	6	7	Jurassic World	Uni.	652270625	2015
	7	8	Marvel's The Avengers	BV	623357910	2012
	8	9	Star Wars: The Last Jedi	BV	620181382	2017
	9	10	Incredibles 2	BV	608581744	2018
	10	11	The Dark Knight	WB	535234033	2008
	11	12	Rogue One: A Star Wars Story	BV	532177324	2016
	12	13	Beauty and the Beast (2017)	BV	504014165	2017
	13	14	Finding Dory	BV	486295561	2016
	14	15	Star Wars: Episode I - The Phantom Menace	Fox	474544677	1999

Dados de Treinamento

Dados de Teste

Ajustar dados de treinamento e teste



Validação cruzada

Id		Título	Estúdio	Receita	Ano
0	1	Star Wars: The Force Awakens	BV	936662225	2015
1	2	Avengers: Endgame	BV	857190335	2019
2	3	Avatar	Fox	760507625	2009
3	4	Black Panther	BV	700059566	2018
4	5	Avengers: Infinity War	BV	678815482	2018
5	6	Titanic	Par.	659363944	1997
6	7	Jurassic World	Uni.	652270625	2015
7	8	Marvel's The Avengers	BV	623357910	2012
8	9	Star Wars: The Last Jedi	BV	620181382	2017
9	10	Incredibles 2	BV	608581744	2018
10	11	The Dark Knight	WB	535234033	2008
11	12	Rogue One: A Star Wars Story	BV	532177324	2016
12	13	Beauty and the Beast (2017)	BV	504014165	2017
13	14	Finding Dory	BV	486295561	2016
14	15	Star Wars: Episode I - The Phantom Menace	Fox	474544677	1999

Dados de Treinamento

Dados de Validação 2

Aplicação K Nearest Neighbors na base de dados Iris

Iris Dataset

Descrição: O conjunto de dados da íris inclui três espécies de íris com 50 amostras cada, bem como algumas propriedades sobre cada flor. Uma espécie de flor é linearmente separável das outras duas, mas as outras duas não são linearmente separáveis uma da outra.

Filename: Iris.data

Colunas:

SepalLength (Cm)	Length of the sepal (in cm)
SepalWidth (Cm)	Width of the sepal (in cm)
PetalLength (Cm)	Length of the petal (in cm)
PetalWidth (Cm)	Width of the petal (in cm)
Species	Species name

Exemplo:

SepalLengthCm	SepalWidthCm	PetalLengthCm	PetalWidthCm	Species
5.1	3.5	1.4	0.2	Iris-setosa
4.9	3.0	1.4	0.2	Iris-setosa
4.7	3.2	1.3	0.2	Iris-setosa
4.6	3.1	1.5	0.2	Iris-setosa
5.0	3.6	1.4	0.2	Iris-setosa

Aplicação K Nearest Neighbors na base de dados diabetes

Pima Indians Diabetes Dataset

Descrição: O banco de dados inclui dados de 768 mulheres com 8 características, em particular.

Filename: pima-insdians-diabetes.csv

Colunas:

1. Number of times pregnant
2. Plasma glucose concentration a 2 hours in an oral glucose tolerance test
3. Diastolic blood pressure (mm Hg)
4. Triceps skin fold thickness (mm)
5. 2-Hour serum insulin (μ U/ml)
6. Body mass index (weight in kg/(height in m)²)
7. Diabetes pedigree function
8. Age (years)
9. Classes: Indica se a pessoa foi diagnosticada com diabetes (1) ou não (0)

Exemplo:

	Pregnancies	Glucose	BloodPressure	SkinThickness	Insulin	BMI	DiabetesPedigreeFunction	Age	HasDiabetes
0	6	148	72	35	0	33.6	0.627	50	1
1	1	85	66	29	0	26.6	0.351	31	0
2	8	183	64	0	0	23.3	0.672	32	1
3	1	89	66	23	94	28.1	0.167	21	0
4	0	137	40	35	168	43.1	2.288	33	1