


Métricas de Erro de Classificação

Matriz de confusão

	Predição Positiva	Predição Negativa	
Atual Positivo	True Positive (TP)	False Negative (FN)	 Erro Tipo II
Atual Negativo	False Positive (FP)	True Negative (TN)	


Erro Tipo I

True Positive (Verdadeiro Positivo):

Previu positivo e é verdadeiro.

Você previu que uma mulher está grávida e ela realmente está.

True Negative (Verdadeiro Negativo):

Previu negativo e é verdadeiro.

Você previu que um homem não está grávido e ele realmente não está.

False Positive (Positivo falso): (erro tipo 1)

Previu positivo e é falso.

Você previu que um homem está grávido, mas na verdade ele não está.

False Negative (Falso Negativo): (Erro Tipo 2)

Previu negativo e é falso.

Você previu que uma mulher não está grávida, mas ela realmente está.

Métricas comuns de aprendizado de máquina

Accuracy (Acurácia): Fração de premissas corretas. Quantidade classificada como Positivos e Negativos corretamente.

$$Accuracy = \frac{TP + TN}{TP + FN + FP + TN}$$

Precision (Precisão): Identificando apenas instâncias positivas. Quantidade positiva classificada corretamente.

$$Precision = \frac{TP}{TP + FP}$$

Recall: Identificando todas as instâncias positivas. Taxa de valores classificados como positivos, comparada com quantos deveriam ser. Qual fração dos positivos o modelo identifica.

$$Recall = \frac{TP}{TP + FN}$$

Receiver Operating Characteristic (ROC) e Area Under Curve (AUC)

ROC mostra o quão bom o modelo criado pode distinguir entre duas coisas.

$$True\ Positive\ Rate\ (TPR) = \frac{TP}{TP + FN}$$

$$False\ Positive\ Rate\ (FPR) = \frac{FP}{FP + TN}$$



Figura 2 Fonte: machine-learning, Intel-ML101-Class5


AUC é uma maneira de resumir a curva **ROC** num único valor.

AUC = 0.0	100% errado
AUC = 1.0	100% certo

Support Vector Machine

Classificação com SVMs

Inclui a maior fronteira possível.



SVM – Lineares

- Obtenção de fronteiras lineares para a separação de dados pertencentes a duas classes.
- As SVMs lineares com margens rígidas definem fronteiras lineares a partir de dados linearmente separáveis.
- Classificadores que separam os dados por meio de um hiperplano são denominados lineares.

A equação de um hiperplano é

$$f(x) = w \cdot x + b = 0$$

Aplicação Support Vector Machine na base de dados de reconhecimento de faces de figuras públicas


Labeled Faces in the Wild Dataset

Descrição: Labeled Faces in the Wild dataset Consiste em milhares de fotos coletadas de várias figuras públicas.

Filename: sklearn.datasets

Colunas:

Exemplo:



Aplicação Support Vector Machine na base de dados Breast Cancer

Breast Cancer Wisconsin (Diagnostic) Dataset

Descrição: Prever se o câncer de mama é maligno ou benigno.

Filename: sklearn.datasets

Colunas:

idID number
diagnosisThe diagnosis of breast tissues (M = malignant, B = benign)
radius_meanmean of distances from center to points on the perimeter
texture_meanstandard deviation of gray-scale values
perimeter_meanmean size of the core tumor
area_mean
smoothness_meanmean of local variation in radius lengths
compactness_meanmean of $\text{perimeter}^2 / \text{area} - 1.0$
concavity_meanmean of severity of concave portions of the contour
concave points_meanmean for number of concave portions of the contour
symmetry_mean
fractal_dimension_meanmean for "coastline approximation" - 1
radius_sestandard error for the mean of distances from center to the perimeter
texture_sestandard error for standard deviation of gray-scale values
perimeter_se
area_se
smoothness_sestandard error for local variation in radius lengths
compactness_sestandard error for $\text{perimeter}^2 / \text{area} - 1.0$
concavity_sestandard error for severity of concave portions of the contour
concave points_sestandard error for number of concave portions of the contour
symmetry_se
fractal_dimension_sestandard error for "coastline approximation" - 1
radius_worst"worst" or largest mean value for mean of distances from center to points on the perimeter
texture_worst"worst" or largest mean value for standard deviation of gray-scale values
perimeter_worst
area_worst
smoothness_worst"worst" or largest mean value for local variation in radius lengths
compactness_worst"worst" or largest mean value for $\text{perimeter}^2 / \text{area} - 1.0$
concavity_worst"worst" or largest mean value for severity of concave portions of the contour
concave points_worst"worst" or largest mean value for number of concave portions of the contour
symmetry_worst
fractal_dimension_worst"worst" or largest mean value for "coastline approximation" - 1

Exemplo:

compactness error	concavity error	concave points error	symmetry error	fractal dimension error	worst radius	worst texture	worst perimeter	worst area	worst smoothness	worst compactness	worst concavity	worst concave points	worst symmetry	worst fractal dimension	TARGET
0.04904	0.05373	0.01587	0.03003	0.006193	25.38	17.33	184.60	2019.0	0.1622	0.6656	0.7119	0.2654	0.4601	0.11890	0
0.01308	0.01860	0.01340	0.01389	0.003532	24.99	23.41	158.80	1956.0	0.1238	0.1866	0.2416	0.1860	0.2750	0.08902	0
0.04006	0.03832	0.02058	0.02250	0.004571	23.57	25.53	152.50	1709.0	0.1444	0.4245	0.4504	0.2430	0.3613	0.08758	0
0.07458	0.05661	0.01867	0.05963	0.009208	14.91	26.50	98.87	567.7	0.2098	0.8663	0.6869	0.2575	0.6638	0.17300	0
0.02461	0.05688	0.01885	0.01756	0.005115	22.54	16.67	152.20	1575.0	0.1374	0.2050	0.4000	0.1625	0.2364	0.07678	0